

# Théorie de l'information : une très rapide introduction

C. Poulliat


16 novembre 2020

# Plan

- 1 Cadre et application
- 2 Sources et canaux
- 3 Information propre
- 4 Entropie d'une variable aléatoire discrète
- 5 Entropie d'une variable aléatoire continue
- 6 Information mutuelle
- 7 Capacité d'un canal discret sans mémoire
- 8 Théorème du codage de canal
- 9 Evaluation numérique

# Modèle de communication

Paradigme de Shannon : communications point-à-point



- **source** : voix, données capteurs, vidéos, etc,
- **codeur** : tout traitement effectué sur la source avant transmission,
- **canal** : vecteur de transport de l'information (liaison téléphonique ou satellite, canal magnétique etc) soumis à des perturbations (bruit, interférence),
- **décodeur** : traitement pour reproduire le plus fidèlement possible la source.

# Modèle de communication

Paradigme de Shannon : communications point-à-point

## But


- Définir un cadre théorique qui permette d'analyser les performances d'un système de communication.
- Quelles fonctions de traitement à l'émission et à la réception ?
- Comment les mettre en oeuvre ?

⇒ Shannon a montré que l'on pouvait séparer les problèmes de mise en forme de la source puis de transmission sur le canal,

⇒ Deux grandes problématiques : compression et codage de canal.

# Modèle de communication

## Séparation des traitements



# Modèle de communication

## Séparation des traitements

- **source** : suite de symboles d'un alphabet donné,
- **codeur de source** : représenter la source par une séquence binaire,
  - ⇒ combien de bit par symbols au minimum pour représenter fidèlement ma source (avec ou sans perte)
  - ⇒ théorie du codage de source avec ou sans perte
- **codeur et décodeur de canal** : introduire de la redondance pour pouvoir corriger des erreurs introduites par le canal et restituer le plus fidèlement,
  - ⇒ comment introduire de la redondance ? Quelle quantité ?
  - Comment décoder ?
  - ⇒ théorie du codage de de canal
- **décodeur source** : restituer la source.

# Notion de Source

## Source d'information et stationnarité

- Une *source d'information* est représentée par une suite de symboles  $(X_0, X_1, \dots, X_n, \dots)$ .  
Chaque  $X_i$  est une variable aléatoire et donc  $\{X_n\}_{n \in \mathbb{N}}$  définit un processus aléatoire. On suppose donc défini

$$p(X_0 = x_0, \dots, X_1 = x_1, \dots, X_n = x_n), \forall n.$$

- Une source d'information est dite *stationnaire* si toute distribution de probabilité de symboles est invariante par translation temporelle.

$$\forall n, \forall l, \forall (x_0, x_1, \dots, x_n) \in \mathcal{X}^n,$$

$$p(X_0 = x_0, \dots, X_n = x_n) = p(X_{0+l} = x_0, \dots, X_{n+l} = x_n)$$

# Source *sans mémoire*

Une stationnaire est dite sans mémoire si les  $X_n$  sont produits de manière indépendante des symboles source passés, ie.

$X_i, \forall i = 0 \cdots n - 1$ . On a ainsi

$$p(X_n | X_{n-1} \cdots X_0) = p(X_n)$$

On en déduit

$$p(X_0, \cdots, X_n) = p(X_0) \cdots p(X_n)$$

On a donc les symboles  $X_i$  indépendants et par stationnarité, les  $X_i$  sont identiquement distribués.

## Source sans mémoire

Une source sans mémoire est définie par une suite de symboles  $X_0, X_1, \cdots X_n$  indépendants et identiquement distribués (i.i.d.).



# Source sans mémoire

## Source discrète sans mémoire

**X** une variable aléatoire discrète à valeurs dans l'alphabet  $\mathcal{X}$  de d.d.p. discrète  $p(x) = \text{Prob}(X = x)$ ,  $x \in \mathcal{X}$ . Une source discrète sans mémoire produit une séquence de symboles i.i.d à valeurs dans  $\mathcal{X}$  et suivant  $p(x)$ .

## Source continue sans mémoire


**X** une variable aléatoire pouvant prendre des valeurs réelles dans un intervalle  $\mathcal{X} \subset \mathbb{R}$  de d.d.p.  $f(X = x)$ . Une source (absolument) continue sans mémoire produit une séquence de symboles i.i.d à valeurs dans  $\mathcal{X}$  et suivant la d.d.p.  $p(x)$ .

## Exemples

symboles  $M$ -aires,  
échantillons Gaussien

# Notion de canal

## Canal discret sans mémoire



- pour un canal discret sans mémoire,  $p(y|x)$  est la probabilité de recevoir  $Y = y$  sachant que l'on a émis  $X = x$ .  $p(y|x)$  est appelée probabilité de transition du canal.
- si  $\mathbf{X}$  est une v.a.  $M$ -aire et  $\mathbf{Y}$  une v.a.  $N$ -aire, on appelle matrice de transition du canal la matrice de taille  $N \times M$  donnée par

$$\Pi = (p(y|x))_{y,x}$$


- la somme de chaque colonne de  $\Pi$  vaut 1 et on a

$$p_Y = \Pi p_X$$

avec  $p_Y = (p(y))_y$  et  $p_X = (p(x))_x$  vecteurs colonnes

# Canal discret sans mémoire


Exemple : le canal à effacement



# Notion de Canal

## Canal à bruit additif

canal additif



$$p(y|x) = p(z = y - x|x) = p_z(y - x)$$

$Z$  est une variable aléatoire indépendante de  $X$

# Canal continu sans mémoire

## Canal à bruit additif Gaussien

### canal additif Gaussien

- $Y = X + Z$  où  $X$  v.a. continue ou discrète à valeurs réelles et  $Z$  est un bruit blanc additif Gaussien de variance  $\sigma_Z^2$ ,
- densité de transition :

$$p(y|x) = \frac{1}{\sqrt{2\pi\sigma_Z^2}} e^{-\frac{(y-x)^2}{2\sigma_Z^2}}$$

# Notion d'information propre

soit  $X$  une variable aléatoire discrète et  $X = x$  un événement de probabilité  $p(x)$

- une mesure de l'information  $h(x)$  s'identifie à une mesure de l'inattendu, de l'improbable

⇒ une information apportée par la réalisation de l'événement  $X$  sera d'autant plus importante que celle-ci est peu probable.

⇒

$$h(x) = f\left(\frac{1}{p(x)}\right)$$

- Propriétés attendues :

- $f(\cdot)$  est une fonction croissante de  $p(x)$ ,
- $f(p) = 0$  quand  $p \rightarrow 1$  (événement certain)
- $f(p.q) = f(p) + f(q)$  (additivité de l'information pour des événements indépendants :  $h(x \text{ et } y) = h(x) + h(y)$ )

# Notion d'information propre

Canal à bruit additif Gaussien

## Unicité de l'information

La fonction  $f(p) = -\log(p)$  est la seule fonction qui soit à la fois positive, continue sur  $[0, 1)$  et qui vérifie l'additivité des informations indépendantes. La base du logarithme est indifférente.

## Définition (Self-information)

Soit  $X$  une variable aléatoire discrète et  $X = x$  un événement de probabilité  $p(x)$ , on appelle information propre ou quantité d'information apportée par l'événement  $x$ , la quantité

$$h(x) = \log\left(\frac{1}{p(x)}\right) = -\log(p(x))$$

# Notion d'information propre

Canal à bruit additif Gaussien

## Propriétés

- positivité :  $h(x) \geq 0$
- additivité : soient  $x$  et  $y$  deux événements indépendants, alors

$$h(x \text{ et } y) = h(x) + h(y)$$

- unités :
  - $\log_e$  : natural units, *nats*, Shannon,
  - $\log_2$  : binary units, *bits*,

## Exemple

- soit une source binaire  $\{0, 1\}$  equidistribuée de symboles indépendants, l'information propre associée à chaque symbole binaire est  $h(1/2) = 1$  bit ou Sh.
- soit une source  $M$ -aire  $\{0, 1, \dots, M-1\}$  equidistribué de symboles indépendants, l'information propre associée à chaque symbole est  $h(1/M) = \log_2(M)$  bit ou Sh.



# Entropie

**X** une variable aléatoire discrète à valeurs dans l'alphabet  $\mathcal{X}$  de d.d.p.  
 $p(x) = \text{Prob}(X = x), x \in \mathcal{X}$

## Entropie

$$\begin{aligned} \mathbf{H}(X) &= - \sum_{x \in \mathcal{X}} p(X = x) \log_2 (p(X = x)) \\ &= -\mathbb{E}(\log_2 p(X)) \end{aligned} \quad (1)$$

⇒ quantité d'information moyenne en bits/symbole


## Propriétés

- $\mathbf{H}(X)$  est déterministe et c'est une fonction de  $p(x)$ ,
- $\mathbf{H}(X) \geq 0$ ,
- $\mathbf{H}(X) = 0 \Leftrightarrow X$  est déterministe ,
- $\mathbf{H}(X) = \log_2 (M)$  pour distribution uniforme de symboles  $M$ -aire,
- invariance par équivalence ( $Y = f(X)$  où  $f(.)$  inversible).



# Entropie

## Entropie binaire



$$X \in \{0, 1\} \text{ avec } p(X = 1) = p$$

$$\mathbf{H}(X) = -p \log_2(p) - (1 - p) \log_2(1 - p) \triangleq H_2(p)$$

# Entropie

## Inégalité de Gibbs

Etant données 2 distributions de probabilité discrètes  $(p_1, \dots, p_n)$  et  $(q_1, \dots, q_n)$  sur un alphabet de même taille, alors on a l'inégalité suivante :

$$\sum_{i=1}^n p_i \log \left( \frac{q_i}{p_i} \right) \leq 0$$

avec égalité pour  $p_i = q_i \forall i$ .

Preuve : utiliser  $\ln(x) \leq (x - 1)$  avec  $x = q_i/p_i$

## Maximum d'entropie

L'entropie d'une source  $M$ -aire vérifie

$$\mathbf{H}(X) \leq \log_2 (M)$$

avec égalité pour source uniforme Preuve : utiliser  $q_i = \frac{1}{M}$



# Entropie conjointe

## Entropie conjointe

soient  $X$  et  $Y$  deux variables aléatoires discrètes

$$\begin{aligned}\mathbf{H}(X, Y) &= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(X = x, Y = y) \log_2 (p(X = x, Y = y)) \\ &= -\mathbb{E}(\log_2 p(X, Y))\end{aligned}\tag{2}$$

## Propriété

$$\mathbf{H}(X, Y) = \mathbf{H}(Y, X)$$

# Entropie conditionnelle

soient  $X$  et  $Y$  deux variables aléatoires discrètes

Entropie de  $Y$  sachant  $X = x$

$$\begin{aligned}\mathbf{H}(Y|X = x) &= - \sum_{y \in \mathcal{Y}} p(Y = y|X = x) \log_2(p(Y = y|X = x)) \\ &= -\mathbb{E}(\log_2 p(Y|X = x))\end{aligned}\quad (3)$$

Entropie conditionnelle

$$\begin{aligned}\mathbf{H}(Y|X) &= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(X = x, Y = y) \log_2(p(Y = y|X = x)) \\ &= \sum_{x \in \mathcal{X}} p(X = x) \mathbf{H}(Y|X = x) = \mathbb{E}(\mathbf{H}(Y|X = x)) \\ &= -\mathbb{E}(\log_2 p(Y|X))\end{aligned}\quad (4)$$

# Entropie conditionnelle et conjointe

## Propriétés

- ① **chain rule** :  $\mathbf{H}(X, Y) = \mathbf{H}(X) + \mathbf{H}(Y|X) = \mathbf{H}(Y) + \mathbf{H}(X|Y)$ ,
- ② **borne inf.** :  $\mathbf{H}(X, Y) \geq \mathbf{H}(X)$  ou  $\mathbf{H}(Y)$
- ③ **Conditionnement** :  $\mathbf{H}(X|Y) \leq \mathbf{H}(X)$   
égalité si  $X$  et  $Y$  indépendants
- ④ **Décroissance par conditionnement** :  
 $\mathbf{H}(X_1|X_2, \dots, X_n) \leq \dots \leq \mathbf{H}(X_1|X_2, X_3) \leq \mathbf{H}(X_1|X_2) \leq \mathbf{H}(X_1)$
- ⑤ **Encadrement (sous additivité de l'entropie)** :

$$\mathbf{H}(X, Y) \leq \mathbf{H}(X) + \mathbf{H}(Y) \leq 2\mathbf{H}(X, Y)$$

- ⑥ **Entropie conjointe et conditionnement** :

$$\mathbf{H}(X, Y|Z) = \mathbf{H}(X|Z) + \mathbf{H}(Y|X, Z)$$

- ⑦ **positivité** :  $\mathbf{H}(X|Y) \geq 0$   
égalité si  $X = f(Y)$  où  $f(\cdot)$  déterministe



# Entropie conditionnelle et conjointe ; cas générale

## Entropie conjointe : borne de l'indépendance

Soit  $X_1, X_2, \dots, X_n$  de loi conjointe  $p(x_1, x_2, \dots, x_n)$

$$\mathbf{H}(X_1, X_2, \dots, X_n) \leq \sum_{i=1}^n \mathbf{H}(X_i)$$

égalité si et seulement si les  $X_i$  sont indépendants

## Chain rule : cas générale

Soit  $X_1, X_2, \dots, X_n$  de loi conjointe  $p(x_1, x_2, \dots, x_n)$

$$\mathbf{H}(X_1, X_2, \dots, X_n) = \sum_{i=1}^n \mathbf{H}(X_i | X_{i-1}, \dots, X_1)$$

# Entropie d'une variable aléatoire continue

## Entropie différentielle

**X** une variable aléatoire continue définie par une densité de probabilité  $f(x)$

### Entropie différentielle

$$h(X) = - \int f(x) \log_2(f(x)) dx. \quad (2)$$

NB : on ne peut pas interpréter  $h(X)$  comme une mesure d'information ou d'incertitude dans le cas continue.

### Changement de variable

soit  $Y = f(X)$ , par changement de variable, on a  $h(X) \neq h(Y) = h(X)$   
donc  $h(X)$  n'est pas une information

### Changement d'échelle

soit  $Y = aX$ , on a  $h(X) \neq h(aX) = h(X) + \log(a)$  qui peut être négatif !



# Entropie d'une variable aléatoire continue

## Exemples

### Loi uniforme sur $[a, b]$

$$f(x) = \frac{1}{b-a}$$

$$h(x) = \log(b-a)$$

### Loi normale de moyenne $\mu$ et variance $\sigma^2$

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$h(x) = \frac{1}{2} \log 2\pi e + \log(\sigma)$$

# Entropie de variables aléatoires continues

## Entropie différentielle conjointe et conditionnelle

### Entropie différentielle conjointe

Soit  $X_1, X_2, \dots, X_n$  avec  $f(x_1, x_2, \dots, x_n)$

$$h(X_1, X_2, \dots, X_n) = - \int f(x_1, x_2, \dots, x_n) \log_2(f(x_1, x_2, \dots, x_n)) dx_1 dx_2 \dots dx_n$$

### Entropie différentielle conditionnelle

$$h(X|Y) = - \int f(x, y) \log_2(f(x|y)) dx dy \quad (7)$$

(8)

# Information mutuelle

## Information mutuelle

$$\begin{aligned} I(X; Y) &= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(X = x, Y = y) \log_2 \left( \frac{p(X = x)p(Y = y)}{p(X = x, Y = y)} \right) \\ &= -\mathbb{E}(\log_2 \left( \frac{p(X)p(Y)}{p(X, Y)} \right)) \end{aligned} \quad (9)$$

## Propriétés

- ❶ **Positivité** :  $I(X; Y) \geq 0$
- ❷ **Borne sup.** :  $I(X; Y) \leq \min(\mathbf{H}(X), \mathbf{H}(Y))$
- ❸ **Symétrie** :  $I(X; Y) = I(Y; X)$
- ❹ **Information propre** :  $I(X; X) = \mathbf{H}(X)$

# Information mutuelle

## Propriétés

- ① Lien avec entropie et entropie conditionnelle :

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

- ② Lien avec entropie et entropie conjointe :

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$


- ③ Conditionnement :  $I(X; Y|Z) \triangleq H(X|Z) - H(X|Y, Z) \geq 0$

- ④ Chain rule :

$$I(X_1, X_2, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y|X_{i-1}, \dots, X_1)$$

# Information mutuelle

## Interprétation



# Information mutuelle

## Interprétation

### Information mutuelle, cas continu

$$I(X; Y) = - \int f(x, y) \log_2 \left( \frac{f(x)f(y)}{f(x, y)} \right) dx dy \geq 0 \quad (10)$$


### Entropie différentielle conditionnelle

$$h(X|Y) = - \int f(x, y) \log_2 (f(x|y)) dx dy \quad (11)$$

$$= h(X, Y) - h(Y) \quad (12)$$

# Capacité d'un canal discret sans mémoire

## Définition



- $X \in \mathcal{X}, Y \in \mathcal{Y}$
- Canal sans mémoire caractérisé par  $p(Y|X)$

## Définition


$$\begin{aligned} \mathbf{C} &= \max_{p(X)} \mathbf{I}(X; Y) \\ &= \max_{p(X)} \mathbf{H}(X) - \mathbf{H}(X|Y) = \max_{p(X)} \mathbf{H}(Y) - \mathbf{H}(Y|X) \end{aligned} \quad (5)$$

Max. atteint pour distribution uniforme pour les canaux *symétriques*.



# Capacité d'un canal discret sans mémoire

Canal à effacement (BEC)




$$\mathbf{C} = 1 - p_e \quad (6)$$

atteint pour une distribution d'entrée uniforme



# Canal binaire symétrique (BSC)



$$\mathbf{C} = 1 - H_2(p) \quad (7)$$

atteint pour une distribution d'entrée uniforme

# Théorème du codage de canal

## Canal discret sans mémoire

### Théorème du codage de canal (1/2)

Soit un canal discret sans mémoire de capacité  $C$ , on peut communiquer pour tout débit de transmission inférieur à  $C$ . En particulier,  $\forall R < C$ , il existe une séquence de codes  $(2^{nR}, n)$  telle que la probabilité d'erreur bloc en sortie de décodage optimal soit arbitrairement petite pour  $n$  suffisamment grand.

# Théorème du codage de canal (2/2)

Canal à temps discret et entrées/sorties continues

## Théorème du codage de canal

- Extension au cas d'entrées ou de sorties continues.
- Les expressions précédentes mettent en jeu des densités de probabilités.
- Application principale : le cas du canal Gaussien.

# Canal additif gaussien(AWGN)

$$\begin{array}{ccccc} & & B(\omega) & & \\ & & \downarrow & & \\ X(\omega) & \longrightarrow & \oplus & \longrightarrow & Y(\omega) \end{array} \quad (8)$$

- $X(\omega)$  tel que  $\sigma_x^2 \leq P$
- $B(\omega) \sim \mathcal{N}(0, \sigma_b^2)$
- 

$$\mathbf{C} = \frac{1}{2} \log_2 (1 + \sigma_x^2 / \sigma_b^2) \text{ bits/symbol} \quad (9)$$

$$= \frac{1}{2} \log_2 (1 + 2R_b E_b / N_0) \quad (10)$$



max. atteint pour  $X(\omega) \sim \mathcal{N}(0, \sigma_x^2 = P)$

## Canal additif gaussien à entrées binaires (BI-AWGN)

$$\begin{array}{ccccc} & B(\omega) & & & \\ & \downarrow & & & \\ X(\omega) & \longrightarrow & \oplus & \longrightarrow & Y(\omega) \end{array} \quad (11)$$

- $X(\omega) \in \mathcal{X} = \{0, 1\}$ , avec  $p(X = 1) = 1/2$
- $B(\omega) \sim \mathcal{N}(0, \sigma_b^2 = N_0/2)$
- canal symétrique :  $p(y|x = +1) = p(-y|x = -1)$


# Canal additif gaussien à entrées M-aire (CI-AWGN)



- $X(\omega) \in \mathcal{X} = \{0, \dots, M\}$ ,  
avec  $p(X = x) = 1/M$
- $B(\omega) \sim \mathcal{CN}(0, \sigma_b^2 = N_0)$

# Canal additif gaussien à entrées M-aire (CM-AWGN)

Comment calculer cette capacité pour une modulation donnée ? (1/2)



- $X(\omega) \in \mathcal{X} = \{0, \dots, M\}$ ,  
avec  $p(X = x) = 1/M$
- $B(\omega) \sim \mathcal{CN}(0, \sigma_b^2 = N_0)$

- Calculer la capacité revient à évaluer

$$\mathbf{C} = \mathbf{I}(X; Y)$$

- Termes à calculer :  $\mathbf{H}(X)$ ,  $\mathbf{H}(X|Y)$ .

# Canal additif gaussien à entrées M-aire (CM-AWGN)

Comment calculer cette capacité pour une modulation donnée ? (2/2)

- Calcul de  $\mathbf{H}(X)$  :  $\mathbf{H}(X) = \log_2(M)$
- Calcul de  $\mathbf{H}(X|Y)$  :

$$\mathbf{H}(X|Y) = -\mathbb{E}(\log_2 p(X|Y)) = \mathbb{E}(h(X|Y))$$

or

$$p(X|Y) = \frac{p(Y|X)}{\sum_{x \in \mathcal{X}} p(Y|X=x)}$$

- Estimateur de  $\mathbf{H}(X|Y)$  : par ergodicité, on a

$$\mathbf{H}(X|Y) = \mathbb{E}(h(X|Y)) = \lim_{N \rightarrow +\infty} \frac{1}{N} \sum_n h(X(n)|Y(n))$$


- Méthode par Monte-Carlo :

- 1 Tirer aléatoirement et uniformément des symboles issue de constellation,
- 2 Calculer pour chaque couple  $(X(n), Y(n))$ ,  $h(X(n)|Y(n))$  et moyenner.



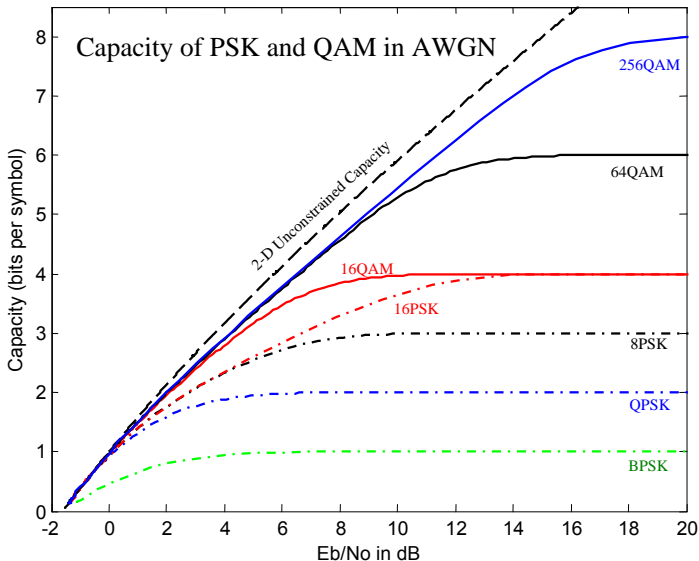
# Canal additif gaussien à entrées M-aires (CM-AWGN)

## Influence du nombre d'échantillons




# Canal additif gaussien à entrées M-aire (CM-AWGN)

## Exemples



## Canaux sélectif en fréquence à entrées binaires(BI-ISI)



$$y[n] = \sum_{k=0}^{L-1} h[k]x[n-k] + b[n] \quad (12)$$

- $X \in \mathcal{X} = \{-1, +1\}$ , avec  $p(X = x) = 1/2$
- $B \sim \mathcal{N}(0, \sigma_b^2 = N_0/2)$

# Comparer l'efficacité des systèmes de codage grâce à la capacité.

